

当 AIGC 遇到了 LLM4Rec

算法小小怪下士

2026 年 1 月 13 日

摘要

随着 AIGC 在推荐系统领域的深入应用，如何利用 LLM 生成既符合用户审美又能提升点击率的创意内容成为研究热点。本文深入探讨了 AIGC 与推荐系统结合过程中的三大核心挑战及解决方案。首先，针对推荐场景中数据稀疏与高噪声问题，总结了基于 PV 分层、置信度加权及跨域迁移的去噪策略；其次，重点分析了后训练在推荐中的落地形式，包括 CTOP 的动态权重 DPO、多模态 Reward Model 的构建以及基于对比学习的协同信号注入方法，论述了如何使 LLM 感知并优化 CTR；最后，探讨了通过 RAG 风格迁移、受控 SFT 及多目标强化学习来平衡生成内容的多样性与质量。

1 怎么解决训练数据不足/含有噪声的问题

1.1 现状：推荐领域本身是高噪声的

小小怪自己通过在之前实习换来一个基本认知：如果认为文案 A 的 CTR 或者其他线上指标高于另一个文案 B，就直接在构建 DPO 的偏序对的时候认为 A 好于 B，这样的方式往往会误导模型的学习。这因为推荐系统中固有的长尾分布的属性导致的，大部分文案都是曝光量较少的，如何在这样高方差的噪声中构建一个高质量的偏序对，是 AIGC 遇到 LLM4Rec 的第一个挑战。

CTOP [4] 通过 PV 对文案进行分层分析，发现在 PV 数较少的组中，Judge 模型难以从 CTR 数据中提取有效信息，效果接近随机猜测。

1.2 方法：根据具体业务数据筛选

RLPF [5] 中 Meta 为了减少小样本带来的高方差噪声，作者只筛选了那些曝光量 (Impressions) 至少达到 2,000 次的广告文案进入训练集。这确保了 CTR 的计算是基于足够样本量的，从而降低了随机波动的影响

PushGen [1] 中快手的具体筛选逻辑如下：

1. 统计硬过滤 (Statistical Hard Filter)

第一步是基于绝对的性能指标设定门槛，剔除质量明显不合格的样本。只有满足以下所有条件的样本才能保留：高点击率 (CTR): 必须大于 0.6%。低短播率 (SVR): 必须小于 40% (防止标题党导致用户点击后立即退出)。高长播率 (LVTR): 必须大于 50% (确保内容具有吸引力)。低负反馈率 (HTR): 必须小于 1% (防止引发用户反感或投诉)。足够的曝光量 (PV): 必须大于 800 次 (确保上述统计数据的置信度)。

2. 标签维度的软过滤 (Tag-wise Soft Filter)

为了避免不同类目 (Category/Cluster) 之间的偏差 (例如某些热门类目天然点击率就高)，采用了“类内分位数裁剪”的方法：在每个 Tag Cluster 内部进行排名。去掉该类目下 CTR 和 LVTR (长播率) 排名后 20% 的样本。去掉该类目下 SVR (短播率) 和 HTR (负反馈率) 排名前 20% 的样本。

3. 置信度加权 (Confidence Weighting) 经过上述两步清洗后的语料库，系统会根据样本的质量和曝光量计算一个“置信度权重”，用于后续模型训练。权重计算考虑了以下因素：CTR: 点击率越高，权重越高。PV: 曝光量越大，数据越可信，权重越高。通过这套流程，PushGen 从百万级的历史推送数据中筛选出了约 7 万条高质量样本构建了清洗后的训练语料库。

1.3 方法：通过 embedding 替代文本

用户的原始点击序列往往包含随机点击或非兴趣相关的“噪声”行为，HLLM-Creator [2] 通过分层建模和辅助任务来提取核心兴趣：

利用 Item LLM 和 User LLM 对用户历史行为进行编码, 而不是直接将原始的长序列文本输入给生成模型。这种结构化的编码方式本身就是一种特征压缩和去噪过程。为了确保提取出的用户 Embedding U 真正反映了用户的核心兴趣 (而非噪声), 论文引入了三个辅助损失函数。语义对齐损失: 利用 LLM 从行为中总结出的文本化“用户兴趣”与 User Embedding 进行对比学习, 强制模型关注用户的核心偏好。重构损失: 要求 User Embedding 能够还原出用户的文本兴趣描述, 保证信息不丢失且聚焦于语义层面。推荐目标损失: 通过预测用户是否点击, 进一步过滤掉对预测行为无效的特征噪声。

1.4 继续预训练

京东 [3] 为了弥补通用 MLLM 在电商领域的知识缺失, 构建了包含 120 万样本的大规模电商多模态数据集进行预训练。主要包含以下三个任务。任务一图像理解: 基于商品图像描述商品主体或背景。任务二多模态内容理解: 结合商品标题、类目等信息生成背景描述。任务三: 生成或重写用于下游图像生成的提示词。

1.5 小小怪自己的想法

针对目标域 (如站外投放场景) 中普遍存在的数据稀疏挑战, 也可以利用跨域迁移学习策略。具体而言, 基于源域 (主站) 与目标域 (站外) 之间共享的物品空间, 我们将源域中积累的丰富用户交互数据作为代理监督信号迁移至目标域, 以推断文案的潜在质量, 从而有效缓解目标域训练样本匮乏的瓶颈。

2 后训练: 怎么把协同信息注入 LLM 中

2.1 DPO: 如何让 LLM 感知到点击率的差异

2.1.1 CTOP 的作法: 改变 loss 的系数

CTOP 并没有改变 DPO 核心的 Log-Sigmoid 结构, 而是通过 Sample Reweighting 的方式修改了目标函数。普通 DPO: 同等看待所有 (y_w, y_l) 数据对。

CTOP 在标准 DPO 损失函数的基础上引入了动态权重机制, 该权重由 CTR 增益和置信度共同决定, 旨在让模型更关注那些“提升明显”且“可信度高”的样本对。CTOP 指出线上反馈存在噪声, 且不同样本带来的 CTR 提升幅度不同。因此, CTOP 为每一个偏好对 (y_w, y_l) 赋予了一个动态权重 w_2 :

$$w_i^{(k)} = gain_i^{(k)} \cdot confidence_i^{(k)}$$

其中 i 表示第 i 个商品, k 表示该商品下的第 k 个偏好对。

增益系数 (Gain Coefficient)。衡量优胜文案 y_w 相比人工基准 y_l 在 CTR 上的相对提升幅度。为了数值稳定性, 论文将其进行了归一化处理:

$$gain_i^{(k)} = \frac{\Delta_i^{(k)}}{\max_{k'} \Delta_i^{(k')}} \times m$$

$\Delta_i^{(k)} = \text{ctr}(y_w^{(k)}) - \text{ctr}(y_l^{(k)})$: 表示 CTR 的绝对差值。

$\max_{k'} \Delta_i^{(k')}$: 表示该商品下所有样本对中的最大 CTR 差值, 用于归一化。 m : 缩放因子, 用于放大微小差异。

置信度系数 (Confidence Coefficient)。通过引入平行的 AA 对照组来验证偏好关系的稳定性。如果实验组和 AA 组的偏好顺序一致, 则置信度高; 否则视为噪声:

$$confidence_i^{(k)} = \begin{cases} 1, & \text{if } (y_w > y_l)_{\text{exp}} \wedge (y_w > y_l)_{\text{AA}} \\ 0.5, & \text{otherwise} \end{cases}$$

当且仅当生成的文案在两个独立流量组 (Exp 组和 AA 组) 中都击败了基准文案时, 权重为 1。如果有矛盾 (说明可能是数据噪声), 权重降为 0.5。

结合上述权重, CTOP 的最终损失函数 $\mathcal{L}_{CTRPO}$ 定义为加权的 DPO 损失之和:

$$\mathcal{L}_{CTRPO} = \sum_{i,k} w_i^{(k)} \cdot \mathcal{L}_{DPO}^{(i,k)}$$

2.1.2 多模态的 Reward Model

京东提出的方法为了模拟用户点击偏好，在预训练 MLLM 基础上微调了一个奖励模型。[3]。对于一对拥有相同属性 i 的商品图像对 (I_1, I_2) ，模型首先通过 Prompt Engineering 构建输入：

$$C_{RM} = f_{instruct}(Q_{RM}, i_1, i_2, \dots, i_n) \quad (1)$$

$$H = \text{LLM}([f_{vision}([I_1; I_2]); f_{text}(C_{RM})]) \quad (2)$$

其中， f_{vision} 和 f_{text} 分别为视觉和文本编码器。

RM 的训练结合了两种损失：二元交叉熵损失，用于学习成对图像的相对 CTR 高低；点回归损失，作为辅助任务，用于预测具体的 CTR 数值以提升细粒度准确性

$$\mathcal{L}_{reward} = \lambda_1 \mathcal{L}_{CE} + \lambda_2 \mathcal{L}_{Point} \quad (3)$$

在生成阶段，利用训练好的 RM 指导 Prompt Model 的微调，Prompt Model 生成背景描述 y ，结合原始商品图 I_o ，输入到 Stable Diffusion 和 ControlNet 中生成最终图像。为了防止过度优化 CTR 而导致背景与商品不匹配（如给化妆品生成运动背景），论文提出了**以商品为中心的偏好优化 (PCPO)**。PCPO 在标准的 DPO 基础上引入了负样本构造策略。通过保留商品信息作为唯一变量，强制模型生成与商品特征一致的背景。

总优化目标为：

$$\mathcal{L}_{opt} = \mathcal{L}_{DPO} + \mathcal{L}_{PCPO} \quad (4)$$

其中 PCPO 的具体形式为：

$$\mathcal{L}_{PCPO} = -\log \sigma \left(\beta \log \frac{PM_{\theta}(y^+ | I_o, C)}{PM_{ref}(y^+ | I_o, C)} - \beta \log \frac{PM_{\theta}(y^+ | \overline{I_o, C})}{PM_{ref}(y^+ | \overline{I_o, C})} \right) \quad (5)$$

这里 $(\overline{I_o, C})$ 代表不匹配的商品信息（通过视觉遮挡或文本替换构造的负样本），旨在惩罚模型在商品信息缺失或错误时仍生成该背景的高概率。

2.1.3 基于对比学习的 CTR 差值注入

在实践中，为了更精细地利用 CTR 数据，也可以引入对比学习损失函数，将 CTR 的绝对差值 (ΔCTR) 作为监督信号传递给模型。我们定义隐式奖励差值为：

$$\Delta r_{\theta} = \beta \log \frac{\pi_{\theta}(y^+ | I_o, C)}{\pi_{ref}(y^+ | I_o, C)} - \beta \log \frac{\pi_{\theta}(y^- | I_o, C)}{\pi_{ref}(y^- | I_o, C)} \quad (6)$$

基于此，我们提出两种改进的损失函数形式：

基于动态边界的三元组损失 (Triplet Loss with Dynamic Margin) 三元组损失的核心思想是拉大正负样本之间的距离。在 CTR 驱动的场景下，正负样本之间的“距离”应当与它们在真实环境中的 CTR 差异成正比。因此，我们将 ΔCTR 映射为动态 margin：

$$\mathcal{L}_{Triplet} = \max(0, \lambda \cdot (CTR(y^+) - CTR(y^-)) - \Delta r_{\theta}) \quad (7)$$

其中， λ 是缩放系数。该损失函数强制模型生成的隐式奖励差值 Δr_{θ} 必须大于由实际点击率差异确定的边界，从而使模型更关注那些 CTR 差异显著的样本对。

基于 InfoNCE 的列表排序损失 (InfoNCE Loss for List-wise Ranking) 为了进一步提升训练的稳定性，我们可以从成对比较 (Pair-wise) 扩展到列表排序 (List-wise)。构建一个正样本 y^+ 和 K 个负样本 $\{y_1^-, \dots, y_K^-\}$ 的集合。利用 InfoNCE 损失函数，最大化正样本相对于所有负样本的互信息：

$$\mathcal{L}_{InfoNCE} = -\log \frac{\exp(\Delta r_{\theta}(y^+)/\tau)}{\exp(\Delta r_{\theta}(y^+)/\tau) + \sum_{k=1}^K \exp(\Delta r_{\theta}(y_k^-)/\tau)} \quad (8)$$

在此框架中, CTR 差值可以通过调整温度参数 τ 来注入, 或者作为样本权重 w_k 加权到损失中:

$$w_k = \phi(CTR(y^+) - CTR(y_k^-)) \quad (9)$$

这种方法允许模型同时对比多个生成的背景描述, 并在高 CTR 差异的负样本上施加更大的惩罚, 从而加速收敛。

2.2 PPO/GRPO: 如何训练一个 Reward Model?

RLPF [5] 是 Meta 发布的一篇用 PPO 生成文案的论文, 其很多认知都像是一两年前的, 没有特别巧妙的技巧。这里主要分享一个 LLM 在推荐领域后训练的基本认知, 我们应该如何训练一个 Reward Model。

Meta 这篇论文的 Reward Model 是在历史 CTR 数据上通过构造成对数据, 使用的是 Bradley-Terry Loss。既然有具体的 CTR 数值, 为什么不直接让模型预测 CTR 数值进行 Regression, 而是只告诉模型 $A > B$? 论文中专门对比了这两种方法, Pointwise 是直接把 CTR 作为 Label 训练模型。Pairwise 把 CTR 差异转化为胜负关系训练模型。作者发现 Pointwise Reward Model 在区分“哪个更好”(Ranking/Ordering) 的能力上不如 Pairwise 模型。这是因为在广告系统中, CTR 的绝对数值受很多外部因素影响(如时间段、受众、图片质量), 波动很大。直接预测绝对值非常困难且容易过拟合噪声。但同一广告下不同文案的相对好坏(A 比 B 好)往往更加稳定。

2.3 SFT:PushGen

PushGen 通过 SFT 后训练, 让生成器擅长“模仿”人类写出通顺、多样的文案, 但它无法预测“效果”。因此 PushGen 的思路是引入 Reward Model, 形成了一个“生成-筛选”的闭环: SFT 负责发散思维生成多个不同风格的候选, RM 负责收敛决策, 挑出那个最能打动用户的。

作者也确实尝试了 DPO、PPO、GRPO, 但是作者分析在推送通知生成的场景中, CTR 对实体显著性(例如提到偶像名字、具体数字)非常敏感。如果直接使用 RL/DPO, 模型容易通过 Reward Hacking 来骗取高分, 导致生成的文案出现幻觉或事实不一致, 这对推送业务是不可接受的。

我觉得作者在 RLHF 满天飞的情况下, 能克制的使用 SFT 是值得赞赏的。

2.4 Soft Prompt:HLLM-Creator

HLLM-Creator 有三个 LLM, 分别用来理解用户, 理解物品和生成创意文本。前两个 item 我们可以把 LLM 就理解成一个特征提取器就可以, 最终的创意 LLM 将 User Embedding 和目标 Item 的文本信息输入到 Creative LLM, 让它生成文本。

历史交互中的 Item 是通过 Item LLM 转化为向量输入给 User LLM 的, 让 User LLM 能感知到用户的历史序列。由于负责提取用户特征的 User LLM (使用 TinyLlama-1.1B) 与负责生成的 Creative LLM (使用 Qwen3-8B) 的模型维度不同, 不能直接输入, 需要通过一个 MLP 对齐维度。对齐后的 User Embedding 被视为一种连续的向量表示(类似于 Soft Prompt), 直接参与后续的计算。

为了能将协同信息加入到 Creative LLM 中, 在训练阶段的辅助任务中, Item LLM 提取的 Item Embedding E 还会与 User Embedding U 一起输入到 Item-User Predictor 中, 用于 CTR 预估, 以对齐协同模式。

3 多样化与质量的平衡

3.1 RAG 搜索高质量样本, 从而进行模仿学习

传统的采样解码往往会导致内容同质化严重或质量下降。CTOP 通过风格迁移与少样本学习来提升生成文案的多样性。它不直接让模型“生成广告”, 而是让模型执行“风格迁移”任务。通过 RAG 检索与当前商品语义相关的高质量样本作为 Exemplars。这些样本通常是经过验证的高 CTR 文案。然后利用预先生成的思维链作为“Imitation tips”, 指导模型分析样本的结构和卖点, 从而生成既具备高质量风格又贴合当前商品的候选文案。这种方法在增加候选数量的同时, 能保持较高的质量, 避免了传统采样中“量多质劣”的问题。配合使用 Top-p 采样、温度系数和重复惩罚等技术手段, 进一步增加生成的随机性和丰富度。

3.2 预先打标+SFT

作者首先预定义了一系列具体的推送风格（例如：悬疑、情感、实用等）。为了让训练数据具备这些风格属性，作者使用一个强大的冻结大模型对历史高质量推送样本进行分类，给每个样本打上<Control Category>的标签。

在 SFT 阶段，作者将“风格标签”显式地作为输入的一部分喂给生成模型。训练输入格式：<任务提示>+<风格类别>+<视频内容描述>。

这样训练出来的模型就建立了一种条件反射：当输入中包含<Suspense>标签时，它就会生成带有悬念语气的文案。在实际推理阶段，系统不再是被动生成，而是主动控制。对于同一个视频，系统会轮询预定义的多个风格标签，强制模型输出不同角度的文案。

3.3 强化学习的多目标奖励函数实现多样性

DIVER [6]，通过 SFT+GRPO 实现多样性，是一个标准的后训练流程。

由于缺乏现成的包含“单一内容对应多条多样化标题”的数据集，论文设计了一套自动化数据生成流程。为了系统地引入多样性，论文定义了三个具体的风格维度，（直观，emoji 使用，四种修辞手法）组合后共形成 16 种独特的标题风格：

通过以下步骤构建训练数据 (x, Y) ，其中 x 为广告内容， Y 为多条多样化标题的集合：

1. **语义与风格标注**：利用 LLM 对现有标题进行标注，提取其语义关键词和风格类型。
2. **受控多样性生成**：给定一段广告内容，提示 LLM 生成多个语义截然不同的关键词，并为每个关键词随机分配一个风格类型。
3. **生成与验证**：基于“内容 + 关键词 + 风格”生成标题，并进行验证以确保生成的标题符合预设的语义和风格约束。
4. **SFT 训练**：使用构建好的数据对模型进行微调，使其学会一次性输出多条风格各异的标题。

SFT 虽然能提供基础的多样性能力，但容易产生重复内容。DIVER 引入了多目标 RL，通过专门设计的奖励函数来明确优化多样性。

多样性奖励 $r_{diversity}$ 由语义多样性和风格多样性两部分组成，其计算公式如下：

$$r_{diversity} = \frac{1 - \text{Pair-BLEU}(Y) + \text{Coverage}(Y)}{2} \quad (10)$$

其中 $Y = \{y_1, \dots, y_N\}$ 表示模型一次生成的 N 个标题集合。

- **语义多样性 (Semantic Diversity)**：通过计算生成集合内标题两两之间的平均 BLEU 分数来衡量冗余度，公式中使用其补数形式：

$$\text{Pair-BLEU}(Y) = \frac{1}{N(N-1)} \sum_{i=1}^N \sum_{j \neq i}^N \text{BLEU}(y_i, y_j) \quad (11)$$

Pair-BLEU 越低，表示标题间的文本重合度越低，语义多样性越高。

- **风格多样性 (Stylistic Diversity)**：由 $\text{Coverage}(Y)$ 衡量，代表生成的标题集合中覆盖了多少种预定义的风格类别。

模型使用 GRPO 算法进行训练，目标是最大化包含多样性、质量和 CTR 在内的综合奖励：

$$\max_{\pi_{\theta}} \mathbb{E}_{x \sim D, Y \sim \pi_{\theta}(x)} [R(x, Y)] - \beta \mathbb{D}_{KL}(\pi_{\theta} || \pi_{ref}) \quad (12)$$

4 工业部署

4.1 未来展望：从 on-policy 走向 online

模型是使用离线历史性能数据训练的。因此，这相当于 offline RL，其中没有与环境的实时交互。为了进一步优化生成模型，可以将大语言模型生成广告的性能结果纳入迭代过程中。这种方法

将更贴近 online RL，其中模型通过采取动作持续与环境交互，并根据奖励和转移的实时反馈进行适应。这样的系统将更能适应新趋势，甚至可能通过探索发现新的趋势，例如，尝试历史数据中未见过的新广告文本。

参考文献

- [1] Bie, S., Cao, J., Luo, Z., Zou, Y., Liang, L., Zhang, L., Chen, L., Liu, Z., Li, X., Zhou, G., Zhan, K., and Gai, K. Pushgen: Push notifications generation with llm, 2025.
- [2] Chen, J., Chi, L., Xu, S., Ran, S., Peng, B., and Yuan, Z. Hllm-creator: Hierarchical llm-based personalized creative generation, 2025.
- [3] Chen, X., Feng, W., Du, Z., Wang, W., Chen, Y., Wang, H., Liu, L., Li, Y., Zhao, J., Li, Y., Zhang, Z., Lv, J., Shen, J., Lin, Z., Shao, J., Shao, Y., You, X., Gao, C., and Sang, N. Ctr-driven advertising image generation with multimodal large language models, 2025.
- [4] Chen, Y., Ren, Z., Gao, Q., Chen, J., Chen, S., Li, X., Ge, T., and Zheng, B. Ctr-driven ad text generation via online feedback preference optimization, 2025.
- [5] Jiang, D. R., Nikulkov, A., Chen, Y.-C., Bai, Y., and Zhu, Z. Improving generative ad text on facebook using reinforcement learning, 2025.
- [6] Wang, C., Yan, S., Yuan, D., Chen, Y., Huang, Y., Zheng, Y., Li, S., Zhang, Y., Chen, K., Zhu, M., and Xu, R. Beyond quality: Unlocking diversity in ad headline generation with large language models, 2025.