

算法小小怪笔记：SNS语料与LLM后训练

SNS（Social Networking Service）是语言的“活化石”，可以捕捉动态、非正式的语料，充满了新词、热梗、缩写和特定社区的“黑话”。因此，SNS语料中蕴含的这种语言活力，无论是对LLM的预训练还是后训练都至关重要，它能有效提升模型对动态、非正式语言的适应能力。今天主要看了一下小红书的NLP团队做的一些搜索领域的后训练的工作。

一、SNS领域大模型的主要挑战

- 任务异构性与复杂性：**SNS场景包含多种任务类型，如内容理解、信息抽取、语义匹配、用户行为建模、对话系统、翻译等。各任务在输入形式、输出格式、评价标准上高度不一致，传统单任务模型难以统一建模。
- 数据分布漂移与语料非正式性**
SNS语料具有强烈的非正式性、情感色彩、语境依赖性，包含大量俚语、缩写、表情符号等。而通用大模型因为存在明显的分布漂移问题，在SNS数据上表现不佳，。
- “跷跷板效应”与灾难性遗忘：**传统的SFT方法在提升领域任务性能的同时，容易牺牲通用能力，尤其是在小规模模型上表现明显。因此模型在适应新任务时可能遗忘之前学到的通用知识。

二、主流后训练方法总结

RedOne

- 继续预训练（CPT）：**在SNS大规模语料上继续预训练，注入领域知识。
- 监督微调（SFT）：**在多任务SNS数据上进行指令微调，提升任务执行能力。
- 偏好优化（PO / RL）：**使用DPO、GRPO等方法进行偏好对齐，提升模型行为的一致性和稳定性。

RedOne 2.0 的改进

提出以强化学习为先导的渐进式对齐策略：

- 探索性学习（RL优先）：**初步对齐SNS领域，识别薄弱任务。
- 针对性微调（SFT）：**针对薄弱任务进行修复，保留通用能力。
- 精炼学习（RL再优化）：**用SNS信号再次强化学习，平滑任务间权衡。

QP-OneModel 的三阶段训练

第一阶段：知识注入

- 利用历史日志中的遗留系统生成伪标签，构建大规模辅助数据集（约 10,000,000 条样本）。

- 采用**混合训练策略**，同时使用：少量人工标注的统一数据（约 10,000 条样本）和大规模单任务伪标签数据
- 损失函数为两者加权和，平衡数据质量与规模。

第二阶段：目标分布对齐

为了与真实线上数据分布对齐，消除伪标签引入的噪声。仅使用**实时人工标注的统一数据SFT**。确保模型与以下两点精确对齐：**严格的统一输出格式**（所有子任务联合标注）和**快速演进的SNS语言趋势**（如新出现的俚语、热点）

第三阶段：逻辑内化

为了让模型真正内化复杂的业务逻辑，而非简单记忆模式。采用多奖励强化学习，使用GRPO优化模型。这里的训练样本是从第二阶段模型中筛选出在特定子任务上表现不一致的样本，实现精准奖励归因。

三、主要效果总结

1. 通用能力与领域能力双提升

- RedOne 2.0 4B 在通用任务上超越多个7B甚至更大规模模型。
- 在SNS-Bench上，4B模型平均得分 **67.57**，超过RedOne-7B（66.88）。
- QP-OneModel 8B 在NER和Term Weighting任务上F1提升分别达 **+9.01%** 和 **+9.31%**。

2. 数据效率显著提升

- RedOne 2.0 使用不到RedOne一半的数据，性能提升 **8.74**。
- QP-OneModel 0.6B 已显著超越BERT基线，证明方法的有效性不依赖模型规模。

四、数据清洗上的trick

1. 粗滤与精滤结合的混合过滤流程

在《RedOne》的CPT阶段，为了从超过1000亿 tokens 的原始数据中筛选出高质量的20B tokens，论文设计了一个两阶段的数据过滤流程：**基于规则的粗滤**：规则包括识别和过滤掉包含**HTML标签**、**乱码**、**过量重复句子**、**特殊字符比例过高等**明显问题的文本。**基于模型的精滤**：在粗滤之后，训练一个小语言模型对数据进行评分。这个模型会评估文本的多个维度，如**连贯性**、**语气恰当性**、**是否符合SNS语境**等，从而筛选出高质量的文本。

2. 通过可扩展的伪标签技术构建监督信号

这是《QP-OneModel》在知识注入阶段解决高质量标注数据稀缺的核心技巧：为了克服人工标注成本高、速度慢的问题，作者利用旧的、由多个独立模型组成的 BERT 流水线系统生成了大规模的“伪标签”。虽然这些伪标签存在噪声且是单任务的，但数据量巨大（约 10^7 条）。通过将它们与少量

人工标注的、高质量的统一数据（约 (10^5) 条）混合训练，模型既学到了广泛的知识，又对齐了精确的业务逻辑。

3. 用于强化学习的偏好数据构造策略

《QP-OneModel》：在多任务强化学习训练中，一个rollout会产出多个子任务的结果。如果直接用一个总的奖励来更新模型，模型很难知道是哪个子任务做得不好。为了解决这个问题，作者先利用第二阶段（SFT）的模型，筛选出“在某个目标任务上奖励分数波动大，但在其他任务上表现稳定”的样本。这样做可以让模型在训练时更准确地理解是哪个具体任务需要优化。

4. 基于最优混合比例的过滤

在《RedOne》的CPT阶段，还应用了 **RegMix** 方法。这可以看作是一种更高级的数据混合策略，通过分析不同数据来源和类型对最终模型性能的影响，来自动寻找并确定一个**最优的数据混合比例**。根据这个分析结果，可以剔除冗余或不必要的数据，只保留最有价值的语料进行训练。

参考文献：

1. RedOne: Revealing Domain-specific LLM Post-Training in Social Networking Services
2. RedOne 2.0: Rethinking Domain-specific LLM Post-Training in Social Networking Services
3. QP-OneModel: A Unified Generative LLM for Multi-Task Query Understanding in Xiaohongshu Search