

推荐系统与LLM词表的思考

一、背景与核心问题

Motivation1:Tiger所提出的SID一个优势在于能够以几千个token来表示千万级的物品数，让LLM当中text+物品交错出现成为可能，但是以往像SID方式来扩充词表，align需要很多高质量数据才能准确的让LLM理解SID，因此这两篇文章都不从SID的方式来适配物品库。

Motivation2：随着大语言模型（LLM）在各类垂直领域（如电商、推荐系统）的广泛应用，研究者发现：模型本身的性能往往不是唯一的瓶颈，输入/输出的表示方式同样至关重要。两篇论文其实都是从“领域推理效率”出发，通用 tokenizer 将领域专有词汇（如品牌名、SKU）切分成多个子词，导致 token 序列变长，推理变慢

《Vocabulary Customization for Efficient Domain-Specific LLM Deployment》
《Unleashing the Native Recommendation Potential: LLM-Based Generative Recommendation via Structured Term Identifiers (GRLM)》

二、提出的解决方案对比

方案维度	词汇定制方法（第一篇）	GRLM（第二篇）
核心思路	扩展 LLM 原有的 tokenizer，加入高频领域词汇	不扩展词表，而是为每个物品生成一组结构化的自然语言关键词（Term IDs）
表示形式	新子词（可能不是完整单词）	完整、规范化的单词序列（如 ["doll", "educational", "wooden", "toddler", "interactive"] ）
是否修改词表	✅ 是，添加新 token	❌ 否，完全使用 LLM 原生词表
如何保证兼容性	将新 merge 操作追加到原有 merge 列表末尾，确保任何输入切分后的 token 数不会比原来多	采用弹性标识符映射：先尝试直接匹配，若失败则通过结构相似性回退，确保总能映射到有效物品
如何让模型学会使用新表示	对扩展后的模型进行继续全参数训练（使用领域数据）	通过集成指令微调，同时优化“物品 →Term ID”识别和个性化推荐两个任务
关键评估指标	token 数量减少比例、推理吞吐量（RPS）、新 token 的使用率	推荐准确率（Recall/NDCG）、标识符有效率（幻觉率）、跨域表现

三、共同的方法论特征

尽管两篇论文的应用场景不同，但它们在方法论上呈现出高度一致的三个设计原则：

1. 不破坏原有能力（向后兼容）

- 词汇定制：新 tokenizer 永远不会比原 tokenizer 切分得更差（token 数量 $\leq$ 原切分）。
- GRLM：弹性映射机制保证生成的标识符总能落地到真实物品，不会输出无效内容。

2. 结构化、数据驱动的扩展

- 词汇定制：基于领域语料训练新 tokenizer，再合并到原 tokenizer。
- GRLM：利用 LLM 自身和邻居物品信息，生成一致且有区分度的关键词序列。

3. 需要继续训练以“内化”新表示

- 两篇论文都强调：仅添加新 token 或生成新标识符是不够的，必须让模型通过训练真正学会使用它们。
 - 第一篇：继续训练后，模型在 >15 个词的序列中 **98%** 的情况会使用新 token。
 - 第二篇：微调后，生成的 Term ID 有效率和直接命中率均超过 **99%**，几乎不产生幻觉。

四、对 LLM 应用设计的共同启示

“表示层不是固定组件，而应与模型参数一起按需适配。”

- 如果你希望 **提升推理效率** → 可以像第一篇一样，**有控制地扩展 tokenizer**，并保证不退化。
- 如果你希望 **提升生成式推荐的质量与泛化能力** → 可以像 GRLM 一样，利用 **LLM 自身词表构建结构化标识符**，避免词表扩展带来的成本。

两种方法**互不冲突**，甚至可以在一个系统中叠加使用：先用词汇定制提升领域输入效率，再用结构化标识符提升推荐语义准确性。

对比维度	词汇定制	GRLM
核心目标	推理效率	推荐质量 + 跨域泛化
表示来源	领域语料	LLM 生成
是否扩展词表	是	否
关键创新	追加 merge 保证不退化	上下文感知生成 + 弹性映射
共同思想	让 LLM 的输入/输出表示与目标任务的分布对齐	相同

