

SID+Text 范式下的能思考的推荐系统

算法小小怪下士

2026 年 3 月 16 日

摘要

工业级推荐系统在过去十年主要采用级联架构，虽然取得了巨大成功，但面临目标不一致、误差累积等固有局限。为了突破这些瓶颈，生成式推荐范式应运而生，将推荐任务重构为端到端的序列生成问题。然而，仅依赖归纳学习的生成式模型仍缺乏世界知识和演绎推理能力。将 SID 融入大语言模型，利用其丰富的世界知识、推理能力和跨域理解能力，成为极具前景的方向。本文系统梳理了当前 LLM as Rec 的核心难点、主流解决方案以及未来可探索的方向，包括 SID 与文本空间的对齐、推理能力的激发、训练策略以及上线权衡等。

1 引言

传统的工业级推荐系统多采用级联架构（召回 → 排序 → 重排），各模块独立优化，导致目标不一致和误差累积。生成式推荐将推荐任务统一建模为序列生成问题，直接输出物品 SID 序列，从原理上缓解了上述问题。然而，这类模型仍停留在“归纳”层面：它们基于用户历史行为统计学习模式，对于稀疏、冷启动或需要常识推理的场景表现不佳。

LLM 天然具备丰富的世界知识、演绎推理能力和跨域理解能力，而 SID 的序列形式恰好适配 LLM 的 Next Token Prediction 训练方式。因此，将 SID 融入 LLM，构建“LLM as Rec”系统，有望同时发挥生成式范式的统一性与 LLM 的推理能力。

当前，该方向存在两大核心难点：

- SID 空间与文本空间的对齐**：训练后可能导致模型语言能力退化，且需要设计合适的任务使 LLM 真正理解 SID 的语义。
- 推理能力的激发与上线平衡**：如何让模型生成可解释的 CoT，同时满足在线服务的低延迟要求。

本文基于现有工作（OneRec-Think [5]、OpenOneRec [7]、Lc-Rec [6]、GREAM [4]、PLUM [3] 等）梳理了上述难点的解决方案，并探讨了未来的研究方向。

2 SID 与文本空间的对齐

2.1 推荐领域的 CPT 语料设计

为了使 LLM 理解 SID 并将其与自然语言对齐，研究者设计了多种交错式训练任务。表 1 总结了主要任务及其特点。

下面对关键任务进行简要说明：

- Interleaved User Persona Grounding**：将用户文本化画像（静态属性、搜索历史、兴趣摘要）与物品 SID 序列交错排列，使模型理解用户语义与物品标识的关联。
- Sequential Preference Modeling**：基于用户历史交互序列预测下一个物品。部分工作（如 Lc-Rec）同时让模型生成下一物品的文本描述，以增强跨模态对齐。
- Item Dense Captioning**：建立 SID 与文本描述的双向生成任务，强制模型理解 SID 的语义内容。可采用 BERTScore 或 LLM-as-Judge 评估生成质量。
- Rec Explanation & Personalized Preference Inference**：引导模型生成推荐理由或用户兴趣分析，需要借助 Teacher 模型或自举数据。

表 1 推荐领域 CPT 任务对比

任务	是否 Instruct	幻觉风险	论文来源
Interleaved User Persona Grounding	否	小	OneRec-Think, OpenOneRec
Sequential Preference Modeling	是	小	OneRec-Think, OpenOneRec, Lc-Rec, GREAM
Item Dense Captioning	是	小	Lc-Rec, OneRec-Think, OpenOneRec, GREAM
Label Prediction	是	大	OpenOneRec
Rec Explanation	是	大	OpenOneRec
Personalized Preference Inference	是	大	Lc-Rec, GREAM
SID 和 text 交错排列	否	是	PLUM

2.2 防止语言能力丧失的策略

引入 SID 训练容易导致 LLM 原有语言能力退化。现有工作提出多种缓解方法：

Token Warm-up: 在继续预训练之前，先冻结 LLM 主体，仅训练新增的物品 token 嵌入，使其快速对齐到语言空间 (OneRec-Think/OpenOneRec)。TS-Rec [1] 使用教师模型为每个 SID token 生成语义描述和关键词，将这些关键词的 embedding 作为 SID token 的初始嵌入，使 SID token 一开始就具备语义基础，相当于 Token Warm-up 的替代方案。

数据混合: 将推荐任务语料与通用语料按比例混合，在后续全参数微调时保持语言能力。

OPD:OpenOneRec 利用原始 Qwen 模型作为教师，对学生模型施加逐 token 的反向 KL 散度奖励。训练时只使用通用 prompt，若学生生成包含 item token 的答案，则施加惩罚，避免模型过度依赖 item token。

Adaptor: OxygenRec [2] 引入 Adaptor，将文本和 ID embedding 映射到共享空间，并采用 Q2I 损失拉近文本指令与目标商品 embedding 的距离。由于 decoder 不生成文本，语言能力不受影响。

3 激发推理能力与上线平衡

3.1 激发推理能力的方法

为了让 LLM 在推荐中展现演绎推理，研究者尝试引入思维链及强化学习。OneRec-Think 采用两阶段方法：先用精简上下文 + 已对齐模型自举生成高质量推理链 (rationale)，再用这些数据训练模型在完整历史下生成同样推理链，本质是将传统 I2I 信息蒸馏给 LLM。为解决奖励稀疏，提出 Rollout-Beam 策略——先生成推理轨迹，然后在此基础上进行 beam search，若搜索结果命中目标物品则给予正向奖励。

GREAM 显式定义推理步骤，通过 LLM 生成 CoT，包括行为证据提取、潜在偏好建模、用户意图推断、推荐理由生成等。采用课程学习逐步增加推理数据比例，并基于生成的语义 ID 与目标 ID 的最长公共前缀长度计算奖励，缓解奖励稀疏。

OneRec-Think 已经展示了模型将 SID 作为语言表达一部分进行【交错推理】的能力。未来推荐系统可演变为理解用户需求的 Agent，例如用户表达情绪“我很 down”，系统结合交互历史，通过推理推荐合适的物品。

3.2 上线权衡

生成式推荐模型直接部署在线服务面临延迟挑战。现有方案提出**快慢思考**结合的模式 (GREAM)：直接序列推荐 (快)：模型直接生成目标商品的语义 ID，适用于高吞吐量、低延迟场景。顺序推理推荐 (慢)：先生成完整推理链，再输出语义 ID，支持可解释性分析和离线研究。OneRecthink 则是采用了 Think-Ahead 的预计算方式，

3.3 模型参数与数据量的权衡

受推荐领域数据量限制，简单的 Scaling Law 未必完全适用。Chinchilla 法则 [7] 提供了模型参数量 N 与训练数据量 D 之间的最优配比：

$$L(N, D) = E + \frac{A}{N^\alpha} + \frac{B}{D^\beta}$$

其中 E 为不可约减的熵。研究团队拟合出大语言模型的参数：

$$L(N, D) = 1.8172 + \frac{482.01}{N^{0.3478}} + \frac{2085.43}{D^{0.3658}}$$

而 OpenOneRec 针对推荐任务的拟合结果为：

$$L(N, D) = 0.4232 + \frac{502.32}{N^{0.3325}} + \frac{7.02}{D^{0.1865}}$$

这表明：

- 推荐任务的 B 值 (7.02) 很小，说明 LLM 的初始参数质量很高，增加数据量能有效提升性能。
- 推荐任务的 E 值更小，反映了推荐数据分布的确定性更高，模型更容易学习。

因此，在推荐领域不应盲目追求模型规模，而应重视数据质量与多样性。

参考文献

- [1] Feng, J., Kong, X., Sheng, L., Wu, B., Yi, C., Yang, F., Sheng, X.-R., Zhu, H., Wang, X., Wu, J., and He, X. Fine-grained semantics integration for large language model-based recommendation, 2026.
- [2] Hao, X., Zhang, M., Li, A., Qian, X., Ma, Z., Zang, Y., Yang, S., Han, Z., Ma, X., Liu, J., Li, Z., Jiang, Z., Wang, S., Tang, N., Qiao, Y., Yang, C., Sun, C., Yuan, J., Peng, C., Hu, H., Yang, P., Yuan, B., Qiu, C., Xing, Z., Yuan, H., Zhang, H., Guo, Y., Ding, W., Gao, J., Huang, H., Chen, Z., Liu, T., and Gong, P. Oxygenrec: An instruction-following generative framework for e-commerce recommendation, 2025.
- [3] He, R., Heldt, L., Hong, L., Keshavan, R., Mao, S., Mehta, N., Su, Z., Tsai, A., Wang, Y., Wang, S.-C., Yi, X., Baugher, L., Cakici, B., Chi, E., Goodrow, C., Han, N., Ma, H., Rosales, R., Soest, A. V., Tandon, D., Wu, S.-L., Yang, W., and Zheng, Y. Plum: Adapting pre-trained language models for industrial-scale generative recommendations, 2025.
- [4] Hong, M., Zhou, Z., Guo, Z., Zhang, Z., Hu, R., Gan, W., Zhu, J., and Zhao, Z. Generative reasoning recommendation via llms, 2025.
- [5] Liu, Z., Wang, S., Wang, X., Zhang, R., Deng, J., Bao, H., Zhang, J., Li, W., Zheng, P., Wu, X., Hu, Y., Hu, Q., Luo, X., Ren, L., Zhang, Z., Wang, Q., Cai, K., Wu, Y., Cheng, H., Cheng, Z., Ren, L., Wang, H., Su, Y., Tang, R., Gai, K., and Zhou, G. Onerec-think: In-text reasoning for generative recommendation, 2025.
- [6] Zheng, B., Hou, Y., Lu, H., Chen, Y., Zhao, W. X., Chen, M., and Wen, J.-R. Adapting large language models by integrating collaborative semantics for recommendation, 2024.
- [7] Zhou, G., Bao, H., Huang, J., Deng, J., Zhang, J., She, J., Cai, K., Ren, L., Ren, L., Luo, Q., Wang, Q., Hu, Q., Zhang, R., Tang, R., Wang, S., Li, W., Wu, X., Luo, X., Wang, X., Hu, Y., Wu, Y., Liu, Z., Zhang, Z., Zhang, Z., Chen, B., Wen, B., Ma, C., Song, C., Chu, C., Lian, D., Yang, F., Jiang, F., Cheng, H., Wang, H., Gai, K., Zheng, P., Wang, Q., Huang, R., Mao, S., Gao, T., Yuan, W., Wang, Y., Zhou, Y., Su, Y., Cheng, Z., Ling, Z., and Li, Z. Openonerec technical report, 2026.