

生成式推荐是伪范式吗？ ——关于 LLM4Rec 与推荐系统演进的思考

算法小小怪下士

2026 年 1 月 20 日

摘要

随着大语言模型的爆发，LLM4Rec 领域如火如荼。本文旨在厘清生成式推荐中的核心概念，探讨从知识增强到模型范式重构的演进路径。文章分析了 Generative Recommender、Generative Retrieval 以及 Semantic ID 的概念，并对推荐系统走向 Scaling Law 的可能性进行了展望。最后，借由科学史的典故，反思了技术探索中“功利性”与“创新性”的辩证关系。

1 引言：概念的边界与澄清

在入门 LLM4Rec 领域时，首要任务是澄清概念的 Scope，唯有如此才能促进社区更准确的交流。目前，“把 LLM 用到推荐系统”这一最大的概念（LLM4Rec）主要可以从以下三个维度进行解构：

- **知识增强**：借助 LLM 强大的语义理解与推理能力，丰富物品内容与用户画像，显著提升推荐系统的解释能力与语义深度。
- **交互增强**：利用 LLM 进行用户行为模拟或冷启动数据扩充，旨在弥补传统推荐中的数据稀疏问题，构建更丰富的交互场景。
- **模型增强**：这是最具变革性的方向。旨在让推荐系统学习 LLM 的结构范式，学习 LLM 的 NTP 的范式，不再局限于判别式地给每个候选集打分，而是实现直接生成下一物品，或者是学习 LLM 的 Transformer 堆叠的结构，走向 scaling law。

2 生成式推荐：愿景与现实

2.1 定义的再思考

狭义且理想的“生成式推荐”，应当如 *OneRec* 所描绘的愿景：实现端到端的推荐，彻底取代传统的“召回 → 粗排 → 精排”级联链路。

然而，当前大部分标榜为 Generative Recommender 的工作，实际上仍聚焦于级联链路中的某一环，例如“生成式召回”或“生成式重排”。还有美团 MTGR 等聚焦于精排的工作，严格意义上更像是在传统精排模式下，对工程及算法效率的优化以逼近 Scaling，而非纯粹的生成式范式。

2.2 为何要做生成式推荐？

- **客观趋势**：在传统推荐模型缺乏 Scaling Law 效应的背景下，随着算力成本的降低，生成式推荐成为了技术突破的必然路径。这里可以吟唱一下周老板在知乎上发的 MFU 作为证据。
- **技术理想**：作为算法工程师，不应仅满足于通过行业规范，更应在理解与遵从的基础上，思考如何重塑行业范式。

2.3 生成式范式的优势

1. **突破判别式天花板**：传统的 Pointwise 判别式模型虽然能快速收敛注意力，但也限制了问题的上限。生成式模型通过提升问题复杂度，有望突破这一天天花板。

2. 压缩即智能：稀疏的离散 ID 表示难以形成丰富的 N-gram 共现 Token。相比之下，语言模型中较小的 Codebook 能够学习到丰富的多元组形式。这也解释了为何单纯增大 Item ID Embedding 维度收益有限——因为可学习的共现信息太少了。
3. 序列长度与搜索深度：更长的解码步长意味着更深的搜索路径。目前的推荐系统主要在“推理宽度”上扩展（如扩大候选池、并行打分），而生成式推荐则在深度上通过序列生成进行探索。
4. 小小怪认为，相较于传统 ID Embedding 方法，Semantic ID 展现出了优越的全域检索能力。这种优势可以归结为训练目标在样本空间覆盖度上的差异：首先，从优化目标来看，生成式范式采用的 Cross-Entropy (CE) 损失函数本质上是在全词表空间进行概率归一化，其在检索任务中的表现普遍优于传统的 Binary Cross-Entropy (BCE)。其次，从负样本规模来看，全域负样本 (Global Negatives) 对模型性能至关重要。过往的实践经验（如腾讯算法大赛方案）及相关研究表明，当 SASRec 等序列模型放弃采样策略，转而使用全域 BCE 进行训练时，其表现足以成为极具竞争力的强基线。因此，Semantic ID 的性能提升在很大程度上源于其规避了采样偏差，直接实现了对全域信息的有效建模

3 被 Overclaim 的“生成式召回”

“生成式召回”这一概念最早由 TIGER 论文 (*Recommender Systems with Generative Retrieval*) 带火。然而，后续许多工作对此概念存在 Overclaim 的嫌疑。

从定义上看，如果“生成式”是指在全域物品上生成下一个物品，那么传统的双塔模型或 SASRec 本质上也是生成式召回。TIGER 的核心贡献其实并非“生成式”这一概念本身，而是用 Semantic ID 替代了原本的 ID Embedding Table。这种替代方案在节省存储空间以及处理冷启动问题上表现优异。因此，当前大多数所谓的生成式召回论文，其内核更偏向于“基于 Semantic ID 的召回”，而非纯粹的生成范式变革。当然，如淘宝 LUM 等工作结合大模型与 ID Embedding，自称为生成式也无可厚非。

4 推荐系统走向 Scaling Law 的路径

目前推荐系统走向 Scaling 主要面临 QPS 的工程瓶颈。单纯以 LLM 为 Backbone、以文本为 Tokenizer 的路径在推理延迟上难以满足工业界要求。目前的探索主要集中在以下方向：

1. 以推荐系统为 Backbone 的生成式召回：以 TIGER 为代表，通过 Semantic ID 走向 Scaling。
2. scalable Token-based Ranking：如字节跳动的 RankMixer、OneTrans 等工作，似乎探索出了另一条 Scaling Law 路径。
3. 预训练大模型辅助判别式：如 GPSD，先预训练一个 Large Model 产出 Embedding，再辅助判别式模型。这种路径在业界尚未引起巨大反响。

5 结语：如何在功利与探索间寻找平衡

今年生成式推荐发展迅猛，上半年的认知到了下半年可能已被颠覆。尽管有时会对某些方案的 Overclaim 感到悲观，但总体而言，这个领域仍有巨大的探索空间和未解难题。期待未来能有真正的，更多的端到端的方案，或者接近端到端的方案，一个生成式推荐 + 生成式重排，取代目前的臃肿的级联链路。

最后引用王小波的一段话：

当年欧几里得讲几何学，有学生发问道：“这学问能带来什么好处？”欧几里得叫奴隶给他一块钱，还讽刺道：“这位先生要从学问里找好处啊！”

又过了很多年，法拉第发现了电磁感应，演示给别人看。有位贵妇人问：“这有什么用？”法拉第反问道：“刚生出来的小孩子有什么用？”

按照功利主义的标准，那个学生和贵妇人似乎更有理——“学以致用，没有用处的学问哪能叫学问？”然而，历史最终站在了欧几里得和法拉第这一边。

时至今日，我们应当意识到，过于直露地寻求“好处”恐怕并非上策。