

Transformer 中的残差连接

算法小小怪下士

2026 年 3 月 19 日

摘要

残差连接是深度神经网络成功的关键之一，但在 Transformer 架构中，简单的加法恒等映射逐渐暴露出信息稀释、梯度不稳定、缺乏选择性等问题。Hyper-Connections (HC) 通过拓宽残差流为多流结构提升了模型容量，却因缺乏约束导致信号指数级爆炸。Manifold-Constrained Hyper-Connections (mHC) 利用双随机矩阵约束恢复恒等映射的稳定性；Attention Residuals (AttnRes) 则引入深度维度的注意力机制，让每一层自适应地聚合前序层输出。我们详细分析了两种方法的数学原理、系统优化及实验效果。

1 引言

残差连接最初以加法形式提出：

$$\mathbf{x}_{l+1} = \mathbf{x}_l + \mathcal{F}(\mathbf{x}_l, \mathcal{W}_l), \quad (1)$$

其核心是恒等映射，保证信号和梯度无损传播。然而，无论是 PreNorm 还是 PostNorm，连接强度均为固定常数，缺乏自适应选择能力。近年来，Hyper-Connections (HC) [1] 将单流残差扩展为多流：

$$\mathbf{x}_{l+1} = \mathcal{H}_l^{\text{res}} \mathbf{x}_l + \mathcal{H}_l^{\text{post}^\top} \mathcal{F}(\mathcal{H}_l^{\text{pre}} \mathbf{x}_l, \mathcal{W}_l), \quad (2)$$

其中 $\mathbf{x}_l \in \mathbb{R}^{n \times C}$ 为 n 条并行流。HC 增强了信息混合能力，但 $\mathcal{H}_l^{\text{res}}$ 的连乘可能导致信号指数级放大或衰减，引发训练不稳定。mHC [2] 通过将 $\mathcal{H}_l^{\text{res}}$ 约束为双随机矩阵，恢复了恒等映射的稳定性。另一方面，Attention Residuals (AttnRes) [3] 将深度维度的信息聚合视为一种注意力机制，使每一层能根据内容选择性地关注前序层输出。

2 标准残差的局限性

标准残差连接在深度方向上执行的是固定权重的累积：

$$\mathbf{h}_l = \mathbf{h}_1 + \sum_{i=1}^{l-1} f_i(\mathbf{h}_i). \quad (3)$$

这种压缩式递推存在三个主要缺陷：

- **缺乏选择性访问**：不同层（如 Attention 和 FFN）对前序信息的依赖模式不同，但固定加法无法区分。
- **不可逆损失**：一旦信息被求和，后续层无法从中单独提取特定层的输出。
- **PreNorm 稀释**：随着层数加深，隐藏状态范数线性增长，导致深层输出占比越来越小，网络不得不放大输出以获取影响力，造成大量冗余层。

3 Manifold-Constrained Hyper-Connections (mHC)

3.1 Seed:HC

HC 通过引入可学习的 $\mathcal{H}^{\text{pre}}, \mathcal{H}^{\text{post}}, \mathcal{H}^{\text{res}}$ 实现了多流混合，但在深层堆叠时：

$$\mathbf{x}_L = \left(\prod_{i=1}^{L-l} \mathcal{H}_{L-i}^{\text{res}} \right) \mathbf{x}_l + \dots, \quad (4)$$




Figure 1 | **Illustrations of Residual Connection Paradigms.** This figure compares the structural design of (a) standard Residual Connection, (b) Hyper-Connections (HC), and (c) our proposed **Manifold-Constrained Hyper-Connections (mHC)**. Unlike the unconstrained HC, mHC focuses on optimizing the residual connection space by projecting the matrices onto a constrained manifold to ensure stability.

图 1 ResNet vs HC vs mHc

若 $\mathcal{H}^{res}$ 的谱半径不为 1, 则复合映射会导致信号指数级爆炸或消失。实验表明, 在 27B 模型上, HC 在约 1.2 万步时出现 Loss 飙升和梯度剧烈波动 [2]。

3.2 双随机矩阵约束的定义和性质证明

mHC 的核心是将 $\mathcal{H}_i^{res}$ 投影到双随机矩阵流形上 1。

矩阵 $\mathbf{M} \in \mathbb{R}^{n \times n}$ 称为双随机的, 若 $\mathbf{M} \geq 0$, 且 $\mathbf{M}\mathbf{1}_n = \mathbf{1}_n$, $\mathbf{1}_n^\top \mathbf{M} = \mathbf{1}_n^\top$ 。

双随机矩阵具有以下优良性质:

1. 谱范数为 1, 即 $\|\mathbf{M}\|_2 \leq 1$, 从而抑制梯度爆炸。
2. 两个双随机矩阵的乘积仍是双随机矩阵, 保证深层复合映射依然稳定。
3. 全体双随机矩阵构成 Birkhoff 多面体, 其顶点为置换矩阵【置换矩阵的定义是每一行/每一列恰巧有一个位置为 1, 其余位置为 0】, 几何上可解释为置换的凸组合。当 $n = 1$ 时, 双随机条件退化为标量 1, 即标准恒等映射。

谱范数为 1. 对于任意双随机矩阵 $\mathbf{M} \in \mathbb{R}^{n \times n}$, 有 $\|\mathbf{M}\|_2 = 1$, 从而 $\mathbf{M}$ 作为线性变换是非扩张的, 即对任意 $\mathbf{x} \in \mathbb{R}^n$, $\|\mathbf{M}\mathbf{x}\|_2 \leq \|\mathbf{x}\|_2$ 。

证 首先, 双随机矩阵的行和均为 1, 因此其无穷范数

$$\|\mathbf{M}\|_\infty = \max_{1 \leq i \leq n} \sum_{j=1}^n |M_{ij}| = \max_i \sum_{j=1}^n M_{ij} = 1.$$

由矩阵范数的基本性质, 谱半径 $\rho(\mathbf{M}) \leq \|\mathbf{M}\|_\infty = 1$ 。另一方面, 注意到全 1 向量 $\mathbf{1}_n = (1, 1, \dots, 1)^\top$ 是 $\mathbf{M}$ 的特征值, 故 $\rho(\mathbf{M}) \geq 1$ 。因此 $\rho(\mathbf{M}) = 1$ 。

现在考虑 $\mathbf{M}$ 的谱范数 $\|\mathbf{M}\|_2 = \sqrt{\rho(\mathbf{M}^\top \mathbf{M})}$ 。由于 $\mathbf{M}$ 是双随机的, $\mathbf{M}^\top$ 显然也是双随机的。根据性质 2 (下文证明), 两个双随机矩阵的乘积仍是双随机的, 因此 $\mathbf{M}^\top \mathbf{M}$ 也是双随机的。对 $\mathbf{M}^\top \mathbf{M}$ 重复上述论证, 可得 $\rho(\mathbf{M}^\top \mathbf{M}) = 1$ 。于是 $\|\mathbf{M}\|_2 = 1$ 。

乘积封闭性. 若 $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ 均为双随机矩阵, 则它们的乘积 $\mathbf{C} = \mathbf{AB}$ 也是双随机矩阵。

证

验证三个条件: 矩阵相乘后的结果满足非负性, 行和为 1, 列和为 1。

非负性: $\mathbf{A}, \mathbf{B}$ 的元素均非负, 故 $C_{ij} = \sum_{k=1}^n A_{ik} B_{kj} \geq 0$ 。

行和为 1: 对任意 i ,

$$\sum_{j=1}^n C_{ij} = \sum_{j=1}^n \sum_{k=1}^n A_{ik} B_{kj} = \sum_{k=1}^n A_{ik} \left(\sum_{j=1}^n B_{kj} \right) = \sum_{k=1}^n A_{ik} \cdot 1 = 1.$$

列和为 1: 同行和为 1 的证明

3.3 Sinkhorn-Knopp 投影

mHC 采用 Sinkhorn-Knopp 算法将任意矩阵投影到双随机流形:

$$\mathbf{M}^{(0)} = \exp(\tilde{\mathcal{H}}_l^{\text{res}}), \quad \mathbf{M}^{(t)} = \mathcal{T}_r(\mathcal{T}_c(\mathbf{M}^{(t-1)})), \quad (5)$$

其中 $\mathcal{T}_r, \mathcal{T}_c$ 分别为行归一化和列归一化。迭代 20 次即可获得近似解。该算法可以直观理解为, 目标是找到一个唯一存在的、与原始矩阵最“相似”的双随机矩阵。每一次的行、列归一化操作, 都是在正确方向上前进的一步 (严格减小与目标的 KL 散度)。这个前进过程不仅有效, 而且效率很高, 能以指数级的速度收敛到目标。

4 Attention Residuals (AttnRes)

4.1 深度维度的注意力机制

AttnRes 将每一层的输入视为对所有前序层输出的加权和:

$$\mathbf{h}_l = \sum_{i=0}^{l-1} \alpha_{i \rightarrow l} \mathbf{v}_i, \quad (6)$$

其中 $\mathbf{v}_0 = \mathbf{h}_1$ (嵌入), $\mathbf{v}_i = f_i(\mathbf{h}_i)$ ($i \geq 1$)。权重由 softmax 归一化给出:

$$\alpha_{i \rightarrow l} = \frac{\phi(\mathbf{q}_l, \mathbf{k}_i)}{\sum_{j=0}^{l-1} \phi(\mathbf{q}_l, \mathbf{k}_j)}, \quad \phi(\mathbf{q}, \mathbf{k}) = \exp(\mathbf{q}^\top \text{RMSNorm}(\mathbf{k})). \quad (7)$$

这里 $\mathbf{q}_l$ 是第 l 层可学习的伪查询向量, $\mathbf{k}_i = \mathbf{v}_i$ 。RMSNorm 防止被大范数输出主导注意力。

为什么要使用伪查询? 从计算效率的角度来看, 如果查询依赖于当前 token 的隐藏状态, 则每个 token 都需要重新计算注意力权重, 而伪查询是固定的, 对所有 token 共享, $\mathbf{q}$ 的计算可以提前或批量进行, 大大降低了训练和推理的 I/O 和计算量。从训练稳定性的角度, 固定查询使得注意力权重仅由层索引决定, 避免了因输入波动导致的权重剧烈变化, 有利于训练稳定。实验表明, 零初始化伪查询可以使训练初期权重均匀, 逐步学习到有意义的深度偏好。从表达能力上, 尽管查询是固定的, 但 key 依然是输入相关的。伪查询仅提供了层间的基础偏好, 实际权重会随着 token 内容动态调整。这既保留了内容依赖性, 又减少了参数量。

并且通过实验现象, 发现不同层的伪查询会导致注意力权重矩阵呈现出特定的模式: 对角线附近权重较高 (表示主要关注前一层), 但也会出现一些离群的高权重点 (表示有选择性地跳过中间层, 直接关注早期层或嵌入)。这证明了伪查询确实学会了有意义的深度注意力模式。

4.2 Full AttnRes 与 Block AttnRes

Full AttnRes 需要存储所有前序层的输出, 内存和通信开销为 $O(Ld)$ 。为适配大规模训练, Block AttnRes 将 L 层划分为 N 个块。如图 2 所示。

- 块内仍用标准残差累加, 形成块表示 $\mathbf{b}_n = \sum_{j \in \mathcal{B}_n} f_j(\mathbf{h}_j)$ 。
- 块间应用注意力, 每个块内第一层只访问之前块的表示, 后续层额外访问当前块的部分。一个块的 hidden states 是通过对该块内所有层的输出进行求和得到的。

内存和通信开销降为 $O(Nd)$, 通常 $N \approx 8$ 即可恢复大部分性能。

5 系统优化

5.1 mHC 的优化

mHC 通过 kernel 融合、混合精度和张量编程框架 TileLang 实现高效计算。在 $n = 4$ 时, 训练开销仅增加 6.7%。




Figure 1: Overview of Attention Residuals. (a) Standard Residuals: standard residual connections with uniform additive accumulation. (b) Full AttnRes: each layer selectively aggregates all previous layer outputs via learned attention weights. (c) Block AttnRes: layers are grouped into blocks, reducing memory from $O(Ld)$ to $O(Nd)$.

图 2 Attention Res

5.2 AttnRes 的优化

训练：跨阶段缓存。在流水线并行中，采用缓存机制避免冗余传输：每个物理 rank 本地缓存已接收的块表示，后续虚拟阶段只传输增量块

推理：两阶段 I/O 调度。利用伪查询与输入无关的特性，将块内所有层的跨块注意力一次性批量计算（Phase 1），再顺序处理块内依赖（Phase 2），使每层 I/O 从 $O(L)$ 降至 $O(S + N)$

长序列预填充。对块表示沿序列维度分片（张量并行），使单设备内存占用从 NTd 降至 $N(T/P)d$ ，结合分块预填充（如 16K chunk）可进一步降低。

6 实验与结论

6.1 mHC 实验结果

在 27B MoE 模型上，mHC 完全消除了 HC 的 loss 飞升现象，最终 loss 比基线低 0.021，下游任务（如 BBH、DROP）提升 2% 以上。复合映射增益稳定在 1.6 以内，相比 HC 的 3000 有量级提升。

6.2 AttnRes 实验结果

在 48B（3B 激活）Kimi Linear 架构上，Block AttnRes 在 1.4T 令牌训练后，所有评估任务均超越基线，尤其推理类任务（GPQA +7.5，HumanEval +3.1）。输出范数呈现周期性有界模式，梯度分布更均匀，缓解了 PreNorm 稀释。缩放定律显示，Block AttnRes 达到与基线 $1.25\times$ 计算量相当的效果。

参考文献

- [1] Defa Zhu et al. Hyper-Connections.
- [2] Zhenda Xie et al. mHC: Manifold-Constrained Hyper-Connections.
- [3] Kimi Team et al. Attention Residuals.