

推荐系统召回篇：I2I 技术的演进

算法小小怪下士

2026 年 3 月 8 日

摘要

在现代工业级推荐系统中，尽管 U2I 的模型结构日益复杂，I2I 召回路径依然是线上不可或缺的关键通道。I2I 不仅能为 U2I 链路提供显著的增量效果，其在冷启动、可解释性及实时反馈方面也具有独特优势。本文旨在梳理从传统启发式 I2I 到深度学习、图嵌入以及大语言模型驱动下的 I2I 演进过程。

1 传统 I2I 召回模型

1.1 启发式关联规则：itemCF 与 Swing

传统的 I2I 模型主要基于协同过滤思想。itemCF 的核心逻辑在于：若大量用户同时喜欢两个物品，则认为这两个物品具有强关联性。然而，itemCF 容易受到热门物品的偏置影响。

Swing 模型对此进行了改进，其引入了用户间的相关性权重。其核心假设是：如果两个物品被大量用户共同喜欢，且这些用户之间的交集较小（即用户群体多样化、相关性低），则这两个物品的关联强度更高，从而有效降低了“小圈子”用户行为带来的噪声。

$$s(i, j) = \sum_{u \in U_i \cap U_j} \sum_{v \in U_i \cap U_j} \frac{1}{\alpha + |I_u \cap I_v|} \quad (1)$$

- U_i 表示喜欢物品 i 的用户集合， U_j 表示喜欢物品 j 的用户集合， I_u 表示用户 u 喜欢的 item 集合， I_v 表示用户 v 喜欢的 item 集合。
- 公式中有两个 sigma 求和符号，表示的是在同时喜欢物品 i 和 j 的用户集合内两两取 pair，因此分子的 1 可以理解为表示一个用户 pair (u,v)。
- 分母中的 I_u 和 I_v 交集的用来表示用户 u 和 v 之间的相似度，等于两个用户共同点击的 item 数量。这个值越高，说明两个用户的重合度越高，就要降低它的贡献度。
- 分母中的 α 是一个平滑项，可以避免分母为零，可以取一个较小的正数，例如 1。

2 图嵌入与深度学习的应用

2.1 基于 Graph Emb

item2Vec 将自然语言处理中的 word2vec 思想引入推荐系统，通过将用户的点击记录视为词序列，利用 Skip-gram 模型学习物品的稠密向量表示。这种方法使得原本离散的物品可以通过向量距离衡量相似度，开启了 I2I 泛化召回的新阶段。

随后的 DeepWalk 进一步将行为序列扩展为行为图。通过在图中进行随机游走，将多用户的行为从“线”扩展到“面”，挖掘出更深层的关联关系。EGES (Enhanced Graph Embedding with Side Information) [3] 由阿里巴巴提出，在 DeepWalk 的基础上引入了物品的 Side Information，有效缓解了冷启动问题。Node2Vec 则通过调节随机游走的权重，在 BFS 和 DFS 之间寻找平衡，从而兼顾了节点的结构相似性和同质性。

2.2 PDN: 统一触发源与目标建模

PDN [2] 的核心思想是将“用户—触发物品—目标物品”($u \rightarrow i \rightarrow j$) 这一推荐路径进行显式建模。该模型通过统一触发源与目标的逻辑, 将最终的关联分数解构为多个概率模块的乘积。PDN 框架主要由四个核心部分组成: Embedding 层负责特征的向量化; TrigNet 用于建模用户对特定触发物品的偏好程度 $P(i|u)$, 即解释“为什么选择该物品作为触发源”; SimNet 则刻画物品间的转移概率 $P(j|i)$, 即两个物品在物理或语义上的关联性; Direct & Bias Net 用于捕捉用户对目标物品的直接偏好及系统的全局偏差。

在线上应用中, PDN 遵循结构化的执行逻辑。首先是索引构建阶段, 利用离线计算好的 SimNet 分数, 为每个物品构建 Top- K 的相似物品索引。其次是 trigger 提取阶段, 当用户进入系统时, TrigNet 根据用户历史实时计算并挑选出 Top- m 个最具代表性的触发物品。最后是 Top- K Retrieval, 系统通过检索这 m 个触发源对应的索引, 产生 $m \times K$ 个候选商品, 并结合用户实时向量完成最终的路径打分。尽管 PDN 实现了路径建模的突破, 但其本质上仍受到双塔架构表达能力的制约。由于模型试图在单一表征空间内平衡“用户—触发源”与“触发源—目标”两个子任务, 容易出现“跷跷板效应”, 即模型可能为了拟合全局点击率而牺牲了对特定长尾路径关联性的深度刻画。

3 近期探索

3.1 早期模型的局限性

传统的 I2I 召回主要依赖“Trigger 选取、Index 召回、后处理排序”三步。这类方法的痛点在于: 其一, Trigger 的选择通常基于人工策略, 缺乏针对不同用户的个性化表达; 其二, I2I 索引本质上是 item-item 的静态映射图, 仅具备记忆能力而缺乏泛化能力。

3.2 Meta 的双塔演进

Meta [1] 在相关视频推荐中提出了平衡语义相关性与 Engagement 的方法。该研究在建模 Trigger Item 时引入了前序用户行为序列, 并增加了一个语义相关性辅助任务。辅助任务的实际效果其实就相当于 target 和 candidate item, 如果内容相近, 就给这一对样本加权重。主任务与辅助任务共享双塔输出的 Embedding, 从而使模型在保证用户点击率的同时, 兼顾内容的语义一致性。通过同时考虑 Trigger 与 Target 的多模态相似度, 探索了召回阶段在 Recall 召回率与语义 Relevance 之间的最优权衡。

3.3 大模型驱动下的 LLM4Rec

小红书的 Notebook LLM [5] 探索了如何将 LLM 与用户行为对齐。其核心逻辑是从用户历史序列中挖掘高频共现的 item-pair, 并基于此构建对比学习任务。在预训练阶段通过微调大模型, 使其学习到的 Embedding 既包含丰富的多模态知识, 又符合用户的点击偏好。这种基于 LLM 生成的 Embedding 为 I2I 召回带来了极强的语义泛化能力。

4 迈向深度的 I2I: 个性化 I2I

淘宝推出的 PI2I [4] 致力于解决传统 I2I 静态化的问题。PI2I 将用户特征、Trigger 特征与 Target 特征共同输入模型, 输出一个标量分值, 从而实现“千人千面”的 I2I 推荐。

4.1 正负样本的定义与训练逻辑

根据 Trigger-Target 的关系, 样本被划分为以下两类:

1. 困难负样本: 来源于与 Target 存在关联的历史 Trigger。若用户历史行为中的物品 i 在静态索引中能召回目标物品 t , 则从该索引列表中选择除 t 以外的物品作为困难负样本。这类样本与正样本极其相似, 强制模型学习更细粒度的区分能力。

2. 简单负样本: 来源于与目标物品无直接关联的历史触发源。若用户历史行为中的物品 j 无法召回目标物品 t , 则从其召回列表中随机采样。这类样本代表了召回空间中的背景噪声。

4.2 训推一致性与分布模拟

引入两类负样本的核心目的在于保证离线训练与在线推理的一致性。在线推理时, 模型会以用户历史序列中的所有物品作为上下文触发器, 候选集 S_{infer} 是所有历史行为触发物品的并集:

$$S_{\text{infer}} = \bigcup_{u \in U_{\text{history}}} \text{i2i_table}(u) \quad (2)$$

若训练阶段仅包含困难负样本，模型虽能区分相似物品，却无法有效抑制由于“无关触发源”带来的噪声。消融实验证明，完全依赖困难负样本会导致次优结果。通过混合采样，困难负样本让模型学会“辨真假”，简单负样本让模型学会“滤噪音”，从而完整模拟推理时的全量候选空间，避免 Distribution Shift。

4.3 PI2I 与前序的 PDN 的工作对比

PDN 侧重于“路径解耦”。它将 $u \rightarrow i \rightarrow j$ 链路拆分为两个独立的概率分布，通过模块化的方式 (TrigNet 和 SimNet) 来分别解决 Trigger 选取的个性化和 Item 相似性的泛化。而 PI2I 更侧重于“全特征交互”。PI2I 倾向于将用户特征、当前 Trigger 特征与 Target 物品特征作为一个整体输入，通过复杂的特征交叉网络直接输出一个标量分数。这意味着在 PI2I 中，物品 i 与 j 的相似度是高度依赖于用户上下文的实时变量，而非 PDN 中相对独立的概率分量。

在工程落地方面，PDN 依然保留了部分传统 I2I 的影子，即依赖于预先构建的 $i \rightarrow j$ 静态或准静态索引。这使得 PDN 在大规模召回时具有极高的性能。而 PI2I 则是向“深度召回”迈进了一步，它通过对所有潜在触发路径的动态打分，实现了更高程度的个性化，但也对在线计算资源提出了更高的挑战。

除此之外，PI2I 还在论文中 release 了淘宝的大规模的召回数据。

5 未来展望：基于 LLM 的世界知识发现

传统 I2I 高度依赖协同过滤的统计规律，这使得模型往往局限于已知数据的“闭环”中。AIGC 与大模型的引入带来了突破“协同茧房”的可能性。

例如，用户喜欢“水烟 (Hookah)”，在协同过滤数据不足的情况下，系统可能无法建立其与“雪茄 (Cigar)”的关联。然而，LLM 凭借其蕴含的“世界知识”和生活常识，能够识别出两者在消费场景和用户画像上的高度重合。这种基于常识的长尾关联具有极高的 Delta Value。这类探索性任务的评估不应仅局限于 AUC 或 Recall。因为这些 Pattern 可能尚未在现有的推荐反馈中显现。或许这些 pattern 并不很多，可以先在静态的 pair 对带来收益，再来衡量未来的发展。至于不如何衡量这种基于 LLM 发现的“潜在兴趣”及其带来的用户长期收益，也必将是 LLM4Rec 领域下一个重要的研究课题。

参考文献

- [1] Jaspal, A., Zhang, F., Chang, W., Kumar, S., Wang, Y., Mittleman, R., Wang, Q., and Mao, W. Balancing semantic relevance and engagement in related video recommendations, 2025.
- [2] Li, H., Chen, Z., Li, C., Xiao, R., Deng, H., Zhang, P., Liu, Y., and Tang, H. Path-based deep network for candidate item matching in recommenders, 2021.
- [3] Wang, J., Huang, P., Zhao, H., Zhang, Z., Zhao, B., and Lee, D. L. Billion-scale commodity embedding for e-commerce recommendation in alibaba, 2018.
- [4] Wang, S., Ma, Y., Fu, K., Wang, Z., Huang, D., Yan, Y., and Wu, J. Pi2i: A personalized item-based collaborative filtering retrieval framework, 2026.
- [5] Zhang, C., Wu, S., Zhang, H., Xu, T., Gao, Y., Hu, Y., Wu, D., and Chen, E. Notellm: A retrievable large language model for note recommendation, 2024.