

策略算法：研究推荐系统的归纳偏置

算法小小怪下士

2026 年 1 月 29 日

摘要

归纳偏置是算法对未知数据的猜测前提。如果归纳偏置太强：模型可能太死板，表现为欠拟合，无法捕捉复杂规律。如果归纳偏置太弱：模型可能想得太多，表现为过拟合，把噪声当规律。本文结合了归纳偏置的概念以及推荐系统中策略算法的工作，通过横向与纵向的双维视角，分析搜广推系统的策略架构及其背后的归纳偏置。首先，文章横向对比了策略团队在不同业务场景下的核心目标与工作范畴。其次，在纵向分析中，本文详细探讨了工业级推荐系统多路召回机制的演进、排序阶段引入因果推断解决选择偏差的逻辑，以及重排阶段多样性打散算法的实践应用。

文章最后提出一点感悟：策略算法的本质是通过业务洞察设计合理的归纳偏置，以弥补纯模型训练在数据分布和冷启动上的局限性。

1 横向分析搜广推策略的种类

表 1 策略团队横向分析

岗位	目标	工作内容
搜索策略	提升搜索入口 DAU，搜索结果页的 CTR 和 CVR	- 制定 Query 实体识别、意图识别策略 - 优化定向和排序策略
推荐策略	提升推荐的 CTR、停留时长和下拉深度；增强留存，最终提升 DAU	- 构建中间指标（APP 在屏时长、用户有效点击比） - 分析推荐策略因子与业务目标的相关性/因果性 - 优化排序策略，监控并调整策略
广告策略	在不影响用户体验的前提下，最大化 CPM	- 广告的投放和流量分发 - 广告的计费、出价、定向、跟单、创意样式等
增长策略	拉新；促活	- 通过广告投放、push 推送、任务激励等拉新 - 对用户进行分层，设计促活和转化策略
内容生态	构建健康内容生态	- 设计内容生产激励体系 - 优化分发（冷启动、多样性调控） - 内容治理（审核、低质识别）
风控策略	预防欺诈、作弊等风险行为	- 构建风险识别特征（行为序列、设备指纹） - 制定分级处置策略（警告、限流、封号） - 对抗黑产，动态更新规则

2 纵向分析（一）：多路召回机制在推荐系统中的应用

在现代工业级推荐系统中，**多路召回**是候选生成阶段的核心范式。其基本思想是：通过多种独立且互补的策略从海量物品库中初步筛选出数百至数千个候选物品，再交由精排模型进行统一打分与排序。常见的召回通道包括：

- 基于物品相似性的 **I2I**（Item-to-Item）召回；
- 基于用户兴趣建模的 **U2I**（User-to-Item）召回；

- 基于用户相似性的 **U2U** (User-to-User) 召回;
- 热门物品 (Popular)、地域偏好 (Geo-based)、内容匹配 (Content-based) 等辅助通道。

2.1 I2I 召回

I2I 召回基于物品之间的相似性进行推荐, 不显式建模用户特征, 其核心假设: “若用户对物品 i 感兴趣, 则其可能也对与 i 相似的物品感兴趣。”

该方法的优点是对新用户友好 (仅需一次交互即可触发推荐), 计算高效, 适用于“看了又看”、“买了又买”等场景。缺点是缺乏全局用户兴趣建模, 难以实现跨品类探索。

2.2 U2I 召回

U2I 召回直接建立用户与物品之间的映射关系, 通过为每个用户生成个性化兴趣向量 $\mathbf{u}$, 并在物品库中检索与其最匹配的物品:

$$\text{score}(u, i) = \mathbf{u}^\top \mathbf{v}_i,$$

其中 $\mathbf{v}_i$ 为物品 i 的嵌入。

典型实现包括双塔模型和 SASRec 为代表的基于 ANN 索引 (如 FAISS) 实现高效检索, 或者以 Tiger 为范式的基于 Beam Search 的生成式模型。该方法的优点是高度个性化, 能融合用户长期与短期兴趣。缺点是对冷启动用户效果较差; 依赖高质量的用户表征学习。

2.3 U2U 召回

U2U 召回首先识别与目标用户行为模式相似的“邻居用户”, 再聚合这些邻居交互过的物品作为推荐候选。比如其表述为“与你兴趣相似的用户喜欢的物品, 你也可能喜欢。”该方法的优点是有助于发现兴趣多样性, 具备一定程度的可解释性 (如“和你相似的人也买了…”)。缺点是在用户行为稀疏时效果不稳定。

2.4 Any2I

我们也不要被上面的三种模式所限制, 实际上可以 Any2I, 比如 U2U2I, Tag2I, U2Author2I。推荐系统的最终目标是 2I, 只是上述的 2I 的过程越多, 最后的效果可能越不可控。

3 纵向分析 (二): Ranking 模型中的 IPW

3.1 从相关性分析到因果推断: 你在观察世界, 还是在干预世界?

相关性分析: 你像是一个带着笔记本的路人, 你观察公园里的人, 你发现: 那些正在锻炼的人, 心肺功能普遍很好。那些坐着不动的人, 心肺功能相对较差。于是得出结论: 锻炼与健康正相关。但是无法排除这些人是不是因为“原本身体就好”才去锻炼的。这叫选择偏差。

因果推断: 你现在是一个“上帝视角”的实验员。你不仅看谁在锻炼, 你还要问: “如果让那个本来不锻炼的人强制去锻炼, 他的健康会变好吗?”

三个假设决定它是“因果”还是“相关”? 如果这三个假设中有任何一个不成立, 你的结论就会滑向“相关性分析”。A. 条件独立性: 你是否漏掉了“幕后黑手”? 假设要求: 你记录了所有影响“锻炼意愿”和“健康结果”的因素 (如年龄、基础病、职业、经济收入)。你把所有这些因素都放进模型算了倾向评分。此时, 加权后的两组人除了“锻炼”这一项, 其他各方面都打平了。如果你漏掉了“基因”这个变量, 那么即使做了 IPW, 锻炼组的健康优势里依然掺杂了基因的功劳。这依然是相关性。B. 正值假设: 是否有人“注定”不锻炼? 假设要求: 无论体质多差或多好, 每个人都有锻炼或不锻炼的可能性。每个人在模型里都有一个大于 0 且小于 1 的概率。这意味着任何特征的人我们都能找到“对照组”。如果所有“重病患者”的锻炼概率都是 0%, 那么你就永远找不到一个“正在锻炼的重病患者”来做对比。你无法推断锻炼对这部分人的因果效应, 结论只能局限在特定人群的相关性上。C. 一致性: 你对比的是同一种东西吗? 假设要求: 处理锻炼的定义必须清晰, 比如所有人所谓的“锻炼”都是指“每天慢跑 30 分钟”。如果处理组里有人是跑马拉松, 有人是散步, 而你把他们混在一起。哪怕你做了加权, 你得到的也是一个模糊的关联, 而不是“慢跑”这个动作对健康的因果效应。

3.2 有哪些因果推断的方法

Re-weighting methods 是解决选择性偏差的通用方法, 常见的经典算法有 IPW, 该方法也是推荐系统内尝试较多的方法之一。阿里大文娱尝试过 Matching methods, 该方法主要通过寻找无偏镜像,

在估计反事实的同时减少了混淆变量带来的估计偏差；Tree-based methods 比较代表性的有因果随机森林；还有比如滴滴有团队在尝试 Multitask Learning Methods。

下面主要介绍 IPW 方法。IPW 的核心直觉：消除“选择偏差”在现实中，人们选择是否接受某种处理（比如：是否锻炼）通常不是随机的。富裕的人可能更倾向于锻炼。年轻人可能更倾向于锻炼。如果你直接比较“锻炼组”和“不锻炼组”的健康水平，你会发现锻炼组更健康。但这可能是因为他们本来就有钱或年轻，而不是锻炼本身的作用。IPW 的做法：给每个样本赋予不同的权重。如果某个特质的人（比如穷人）很少去锻炼，那么一旦某个穷人锻炼了，我们就给他更大的权重，让他代表更多像他一样但没去锻炼的人。

1. 计算 Propensity Score。利用协变量 X （如年龄、收入、病史等）估计每个个体进入处理组的条件概率：

$$e(X_i) = P(Z_i = 1|X_i)$$

2. 计算 Calculating Weights。根据个体实际接受的处理情况 Z_i ，构造权重 W_i 。其核心思想是使稀有样本获得更大的表征能力：

$$W_i = \frac{Z_i}{e(X_i)} + \frac{1 - Z_i}{1 - e(X_i)}$$

其中：若个体属于处理组 ($Z_i = 1$)，权重为 $W_i = \frac{1}{e(X_i)}$ 若个体属于控制组 ($Z_i = 0$)，权重为 $W_i = \frac{1}{1 - e(X_i)}$

3. 计算平均处理效应在加权后的伪人群中，处理分配与协变量 X 已实现平衡。此时，平均处理效应 τ_{ATE} 可通过加权平均值之差获得：

$$\hat{\tau}_{ATE} = \frac{1}{n} \sum_{i=1}^n \frac{Z_i Y_i}{\hat{e}(X_i)} - \frac{1}{n} \sum_{i=1}^n \frac{(1 - Z_i) Y_i}{1 - \hat{e}(X_i)}$$

其中： n 为总样本量。 Y_i 为个体 i 观测到的结果变量。

3.3 因果推断在 ranking 中有什么用

比如在电商场景，CVR 目标训练在点击空间，推理却在整个曝光空间，两个空间的样本分布不一致，存在样本选择偏差问题。因此，可以使用因果推断的反事实建模方法在曝光空间建模 CVR，实现 CVR 模型在曝光空间的无偏训练。

那么 IPW 方法是如何在这里实现“无偏”？我们可以把点击行为看作是因果推断中的 Z ， $Z = 1$ 表示被点击， $Z = 0$ 表示未被点击。按照上述描述的步骤，第一步：计算 Propensity Score。在这里，倾向评分 $e(X)$ 就是用户的 CTR。

$$e(X_i) = P(Z_i = 1|X_i)$$

我们利用曝光数据训练一个 CTR 模型，预测一个商品在给定特征 X 下被点击的概率。

第二步：计算权重 W 对于那些已经点击并进入 CVR 训练集的样本 ($Z = 1$)，我们给它施加一个逆概率权重：

$$W_i = \frac{1}{CTR_i}$$

这里 reweight 的一个逻辑就是如果一个商品 CTR 很低，但用户竟然点了它并发生了转化。这个样本非常“稀有”，代表了大量“由于 CTR 低而没被观察到”的潜在转化可能。IPW 给它 100 倍的权重，让它在训练 CVR 时“代表”那 100 个具有类似特征但没被点击的样本。

第三步：在曝光空间训练通过对点击样本加权，我们实际上在 CVR 模型面前模拟出了全量曝光空间的分布。此时，CVR 模型的 Loss 函数变为：

$$\mathcal{L}_{CVR} = \sum_{i \in Clicked} \frac{1}{CTR_i} \cdot \text{loss}(y_i, \hat{y}_i)$$

这样训练出来的模型，就具备了在曝光空间进行准确预测的能力。

除了 IPW，蚂蚁团队在 23 年发布的 DCMT，建模了一个反事实 CVR 塔，也是将因果建模用在 Ranking 中的一个例子。

3.4 小小怪 Remark

第一个问题：LLM 进行推理，真的需要完全满足因果关系的数据或者推理吗。

目前的 LLM 本质上是概率性的文本补全。它能处理复杂问题，是因为在海量数据中，CoT 被作为一种高维统计模式记录了下来。当问题在 LLM 的预训练语料范围内时，它可以通过相关性完美“模仿”推理过程。因此目前大模型的智能的涌现可以看作是通过大量“相关性”语料实现的。

但为什么我们可能还需要强因果性的内容：一方面是防止幻觉：LLM 经常会出现逻辑断裂，虽然每一步看起来都对，但因果链条是断的。引入因果性可以作为一种逻辑约束，确保每一步推理都有物理或逻辑上的支撑。还有就是 OOD 泛化：当面临全新的、未见过的场景时，基于相关性的模型会失效，而因果模型能保持鲁棒。

第二个问题 LLM4Rec：引入世界知识到推荐系统时需要强因果吗。

在 LLM4Rec 场景下，强因果性是或许不可或缺的。因为当引入世界知识时，会引入大量的混杂因素。例如：世界知识告诉你“冬天人们喜欢滑雪”。如果基于“冬天 → 滑雪”的相关性，模型可能推荐滑雪板给南方人。而因果知识，模型需要理解“地理环境”是滑雪的前置因果条件。如果不建模这种因果逻辑，模型引入的知识越多，噪声和偏差就越大。

4 纵向分析 (三)：重排打散策略

1. 规则硬打散

作为最基础的兜底策略，通过强制约束（如：每 5 个内容中图文不得超过 2 个、一级类目重复上限为 1）实现多样性。其效果高度依赖类目识别的准确度；若底层标签不准，规则容易失效，需引入细粒度标签或转向软打散策略。

2. 向量空间打散

利用 item 的向量距离进行软性干预。相比硬规则，其过渡更自然，但打散效果受限于 Embedding 的表征质量，可能出现难以解释的 Bad Case。

3. MMR 算法软打散 (Maximal Marginal Relevance)

核心思想：MMR 通过贪心策略在“相关性”与“多样性”之间寻找最优平衡。

工作流程：

- **初始化：**首先从待排池中选出与用户 Query 相关度最高的物品放入结果集。
- **迭代计算：**在后续选取中，不仅考虑物品自身的相关得分，还要计算其与“已选集合”中物品的最大相似度。
- **评分公式：**选择使下式最大化的物品 D_i ：

$$MR = \arg \max_{D_i \in R \setminus S} \left[\lambda \cdot \text{Sim}_1(D_i, Q) - (1 - \lambda) \cdot \max_{D_j \in S} \text{Sim}_2(D_i, D_j) \right]$$

其中 λ 是调节因子： λ 越大，排名越偏向相关性； λ 越小，则越强调多样性（即惩罚与已选内容相似的物品）。

4. 分桶蛇形打散

按属性将 item 预分桶，通过蛇形遍历（蛇形遍历相比于普通遍历，能尽量减少邻近的重复）。从各桶中轮询抽取。该方法实现简单，但若各桶数据量不均衡，容易导致列表尾部出现单一类型堆积。

5. 滑动窗口局部打散

基于局部视野的交换策略。在固定长度的窗口内，若同属性内容超过阈值，则与窗口后方的异质 item 交换位置。其优势在于计算量低、局部保序性好，适用于对实时性要求高的信息流场景。

6. 加权分数干预 (Weight-based Scoring)

为 item 的不同属性分配权重 w_i ，结合计数因子进行动态调分。

$$f(x) = \sum_i W_i \cdot \text{Count}_i$$

该方法扩展性强，支持多维度属性叠加，但参数调优较复杂，且在全局分布不均时仍可能出现末尾扎堆现象。

5 一些感悟：策略的目标是研究推荐系统的 inductive bias

我认为一言以蔽之，策略算法/产品的目标就是通过业务洞察，设计一套最符合当前商业目标的偏置规则，去引导算法跑出你预想的结果。

这种策略算法是有必要的，目前很难通过一个模型参数来拟合复杂的推荐系统，即使 OneRec 也受限于其数据分布，在冷启动上表现出较差的性能。哪怕不是 OneRec 这个新模型，就谈论传统模型，其也难免受限于数据分布决定模型效果。比如快手的数据分布中大部分都是土味视频，这样训出来的模型至少在冷启动的时候难免会多吐土味视频，这对吸引年轻人很不友好，因此做用户分层其实就是一种归纳偏置，通过 boost 一些内容，来吸引年轻人。

同样的在电商场景，我们也会将一些归纳偏置融入，比如针对用户进行分层，不同类型的用户使用的召回路和每一路召回的数量应该不一样。可以按照最近一次消费时间、消费频率、消费金额对用户进行分层。实际工作中，我们还可以用更多维度对用户进行分层，比如用户登录频次、用户使用时长、用户浏览商品数等。对于内容推荐场景来说也是一样的，可以依据用户登录频次、使用时长、内容浏览数、内容互动数等方面进行分层。对用户的分层决定了后面的召回策略的设计。

表 2 用户分层

客户等级	最近一次消费时间	消费频率	消费金额	客户属性
L1	高	高	高	高净值用户
L2	高	低	高	核心发展用户
L3	低	高	高	核心保持用户
L4	低	低	高	核心挽留用户
L5	高	高	低	一般价值用户
L6	高	低	低	一般发展用户
L7	低	高	低	一般保持用户
L8	低	低	低	低价值用户

在推荐系统工程实践中，产品的交互样式也是算法底层逻辑的一种 Inductive Bias。这种偏置通过改变用户与系统的博弈关系，深刻影响了流量分发机制、系统容错率以及用户的心理预期。

1. 相比于视频业务，电商业务的属性决定其必须采用去中心化的分发机制。
2. 单列全屏样式的内容推送，其核心特征为用户丧失了显性的内容选择权，系统执行完全的“强行喂养”机制。为了保证观看体验，系统倾向于分发具备“高公约数”属性的热门内容。这种偏置使得爆款视频更容易获得超量曝光，但也导致算法更倾向于在用户已知兴趣域内收敛，而非探索新奇领域，从而形成强烈的精神依赖。
3. 以小红书为代表的双列样式，通过一屏展示多个内容，将部分选择权交还给用户。这样的推送样式允许算法进行更大胆的内容探索，分发更多长尾或异质化内容，从而构建出更具包容性和多样性的内容生态。

参考文献

《搜广推策略产品经理》